מסמך הנחיות פנימי: פרויקט RAG ומדיניות AI

תאריך עדכון: 15 באוקטובר 2024 | מחבר: הנהלת הפיתוח

מסמך זה מרכז את הדרישות הטכניות, מגבלות התקציב ומדיניות העבודה עבור צוות הפיתוח שמוביל את פרויקט ה-Retrieval-Augmented Generation (RAG) בחברה. מטרת הפרויקט היא לאפשר לעובדי החברה לתשאל מסמכים פנימיים בצורה מאובטחת וללא זליגת מידע החוצה. הארכיטקטורה מבוססת על שילוב של סביבת React בצד הלקוח, ושרת מקומי מבוסס Python.

מגבלות חומרה ותקציב מחשוב

הנחיה קריטית: עקב מגבלות תקציב, יש להריץ את סביבת הפיתוח המקומית על גבי חומרה קיימת מסוג **NVIDIA GTX 1050**. אין אישור לרכוש כרטיסי מסך חדשים ברבעון הנוכחי, ולכן חובה להשתמש ב-Ollama לפריקת עומסים למעבד (CPU).

רכיב מערכת	המודל המאושר	מגבלת שימוש / הערות
המרת טקסט למספרים (Embeddings)	nomic-embed-text	עיבוד חופשי וללא הגבלה מקומית.
מסד נתונים וקטורי (Vector DB)	ChromaDB	יש לשמור את המסד מקומית, מגבלה של 5GB.
מודל שפה (LLM)	Llama 3 (8B)	זמן תגובה מצופה בפיתוח: עד 45 שניות לשאילתה.
תקציב גיבוי לענן (OpenAI API)	GPT-4o-mini	מוגבל ל-$20 בחודש לכל מפתח עבור בדיקות בלבד.

מדיניות עובדים בצוות ה-AI

עובדי הפיתוח בצוות זכאים ל-14 ימי מחלה בשנה, הניתנים לניצול מלא. בנוסף, כל מפתח צובר קרן השתלמות טכנולוגית בסך 500 שקלים בחודש, המיועדת לרכישת קורסים מקוונים או רישיונות תוכנה (כגון GitHub Copilot).

תרשים זרימת הנתונים בפרויקט (RAG Pipeline)

